



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΔΠΜΣ ΕΠΙΣΤΗΜΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗΝ

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Ακαδημαϊκό έτος 2025-26, Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Διδάσκοντες: Δημήτριος Τσουμάκος, Ιωάννης Κωνσταντίνου

Υπεύθυνος Εργαστηρίου: Νικόλαος Χαλβαντζής

7 Μαΐου 2026

Εξαμηνιαία Εργασία

Περιγραφή

Στην παρούσα εξαμηνιαία εργασία ζητείται ανάλυση σε (μεγάλα) σύνολα δεδομένων, εφαρμόζοντας επεξεργασία με τεχνικές που εφαρμόζονται σε data science projects. Τα εργαλεία που θα χρησιμοποιηθούν στα πλαίσια του project είναι τα [Apache Hadoop](#) (version ≥ 3.0) και [Apache Spark](#) (version ≥ 3.5). Καλείστε να χρησιμοποιήσετε τους πόρους που σας διατίθενται στο ειδικά διαμορφωμένο περιβάλλον που έχει δημιουργηθεί για εσάς και στο οποίο μπορείτε να αποκτήσετε πρόσβαση ακολουθώντας τους εργαστηριακούς οδηγούς του μαθήματος. Συνοπτικά, ο σκοπός της εργασίας είναι:

- η εξοικείωση και ανάπτυξη των δεξιοτήτων των σπουδαστών στην εγκατάσταση και διαχείριση των κατανεμημένων συστημάτων Apache Spark και Apache Hadoop.
- Η χρήση σύγχρονων τεχνικών μέσω των API του Spark για την ανάλυση δεδομένων όγκου.
- Η κατανόηση των δυνατοτήτων και περιορισμών των εργαλείων αυτών σε σχέση με τους διαθέσιμους πόρους και τις ρυθμίσεις που έχουν επιλεγεί.

Δεδομένα

Στην παράγραφο αυτή θα παρουσιαστούν τα δεδομένα που θα κληθείτε να χρησιμοποιήσετε στα πλαίσια της εξαμηνιαίας εργασίας. Πρόκειται για δημοσίως διαθέσιμα και δωρεάν σύνολα δεδομένων που έχουν περισυλλεγεί από διαφορετικές πηγές.

Προς διευκόλυνσή σας, όλα τα απαραίτητα σύνολα δεδομένων είναι προσβάσιμα στο παρακάτω directory του HDFS: `hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/`.

Σύνολο Δεδομένων	S3 URI
Los Angeles Crime Data (2010-2019)	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_Crime_Data/LA_Crime_Data_2010_2019.csv
Los Angeles Crime Data (2020-2025)	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_Crime_Data/LA_Crime_Data_2020_2025.csv
Census Blocks	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_Census_Blocks_2020.geojson
Census Blocks Fields	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_Census_Blocks_2020_fields.csv
Median Household Income by Zip Code	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_income_2021.csv
LA Police Stations	hdfs://hdfs-namenode.default.svc.cluster.local:9000/data/LA_Police_Stations.csv

Πίνακας 1: Σύνολα Δεδομένων και οι τοποθεσίες όπου βρίσκονται στο HDFS.

Los Angeles Crime Data^{1 2} : Προέρχεται από το δημόσιο αποθετήριο δεδομένων της κυβέρνησης των Ηνωμένων Πολιτειών της Αμερικής³ . Περιλαμβάνει δεδομένα καταγραφής εγκλημάτων για την πόλη Los Angeles από το 2010 μέχρι το 2025 χωρισμένα σε δύο μέρη (2010-2019, 2020-2025). Στους σχετικούς συνδέσμους μπορείτε να βρείτε τις περιγραφές των δεδομένων για κάθε πεδίο (column).

Census Blocks (Los Angeles County)⁴ : Σύνολο δεδομένων που περιέχει απογραφικά στοιχεία της Κομητείας του Los Angeles για το έτος 2020 σε [geojson](#) format. Συνοδεύεται από αρχείο με περιγραφές των πεδίων του (Census Blocks Fields).

Median Household Income by Zip Code (Los Angeles County)⁵ : Σύνολο δεδομένων που περιέχει δεδομένα σχετικά με το μέσο εισόδημα ανά νοικοκυριό για κάθε ταχυδρομικό κώδικα (ZIP Code) στην Κομητεία του Los Angeles. Για διευκόλυνση, τα δεδομένα έχουν συλλεχθεί και αποθηκευθεί σε csv format – ως delimiter, ο χαρακτήρας “;”. Αναφέρεται σε στατιστικά στοιχεία του έτους 2021.

LA Police Stations⁶ : Μικρό σύνολο δεδομένων που περιέχει δεδομένα σχετικά με την τοποθεσία των 21 αστυνομικών τμημάτων που βρίσκονται στην πόλη του Los Angeles.

Ερωτήματα

Query 1

Να ταξινομηθούν, σε φθίνουσα σειρά, τα τμήματα της ημέρας ανάλογα με το ποσοστό καταγραφών εγκλημάτων επί του συνόλου που έλαβαν χώρα στο δρόμο (“STREET”), με φθίνουσα σειρά. Θεωρείστε τα εξής τμήματα μέσα στη μέρα:

- Πρωί: 5.00πμ – 11.59πμ
- Απόγευμα: 12.00πμ – 4.59πμ
- Βράδυ: 5.00πμ – 8.59πμ
- Νύχτα: 9.00πμ – 4.59πμ

Query 2

Να βρεθούν, για κάθε έτος, οι 3 μήνες με τον υψηλότερο αριθμό καταγεγραμμένων εγκλημάτων. Ζητείται να τυπωθούν ανά έτος οι συγκεκριμένοι μήνες, ο συνολικός αριθμός περιστατικών, καθώς και η θέση του συγκεκριμένου μήνα στην κατάταξη του αντίστοιχου έτους. Τα αποτελέσματα να δοθούν σε σειρά αύξουσα ως προς το έτος και φθίνουσα ως προς τον αριθμό καταγραφών και την κατάταξη (δείτε παράδειγμα στον Πίνακα 2).

¹<https://data.lacity.org/Public-Safety/Crime-Data-from-2010-to-2019/63jg-8b9z>

²<https://data.lacity.org/Public-Safety/Crime-Data-from-2020-to-Present/2nrs-mtv8>

³<https://catalog.data.gov/dataset>

⁴<https://data.lacounty.gov/maps/lacounty::2020-census-blocks>

⁵http://www.laalmanac.com/employment/em12c_2021.php

⁶<https://geohub.lacity.org/datasets/lahub::lapd-police-stations/explore>

year	month	crime_total	ranking
2010	2	2145	1
2010	3	1492	2
2010	5	54	3
2011	12	4632	1
2011	6	2312	2
2011	4	312	3
⋮			

Πίνακας 2: Υπόδειγμα αποτελέσματος Query 2

Query 3

Χρησιμοποιώντας ως αναφορά τα δεδομένα της απογραφής 2020 για τον πληθυσμό και εκείνα της απογραφής του 2021 για το εισόδημα ανα νοικοκυριό, να υπολογίσετε για κάθε ZipCode του Los Angeles το μέσο ετήσιο κατακεφαλήν εισόδημα για τη διετία 2020-2021.

Query 4

Να υπολογιστεί, ανά αστυνομικό τμήμα, ο αριθμός εγκλημάτων που έλαβαν χώρα πλησιέστερα σε αυτό από οποιοδήποτε άλλο, καθώς και η μέση απόστασή του από τις τοποθεσίες όπου σημειώθηκαν τα συγκεκριμένα περιστατικά. Τα αποτελέσματα να εμφανιστούν ταξινομημένα κατά αριθμό περιστατικών, με φθίνουσα σειρά (δείτε παράδειγμα στον Πίνακα 3).

division	average_distance	#
77TH STREET	2.208	7045
RAMPART	2.009	4595
FOOTHILL	3.597	3047
PACIFIC	2.739	2132

Πίνακας 3: Υπόδειγμα αποτελέσματος Query 4.

Ζητούμενα

1. Τα δεδομένα είναι αποθηκευμένα κυρίως σε μορφή csv. Είναι αυτό το καταλληλότερο μορμάτ για επεξεργασία από το Spark; Ποιά άλλα εναλλακτικά μορμάτ γνωρίζετε που μπορούν να χρησιμοποιηθούν και σε τι διαφέρουν; Επιλέξτε ένα από αυτά, μετατρέψτε τα δεδομένα στο συγκεκριμένο μορμάτ και συγκρίνετε τη διαφορά στην επίδοση (χρόνο εκτέλεσης) σε σχέση με το csv για κάποιο από τα **Queries**.
2. Να υλοποιηθεί το **Query 1** χρησιμοποιώντας τα DataFrame (με και χωρίς UDF) και RDD APIs. Να εκτελέσετε και τις δύο υλοποιήσεις με 2 executors (1 core, 2GB memory). Υπάρχει διαφορά στην επίδοση μεταξύ των τριών υλοποιήσεων; Να σχολιάσετε τα ευρήματά σας. (%)
3. Να υλοποιηθεί το **Query 2** χρησιμοποιώντας τα DataFrame και SQL APIs. Να εκτελέσετε και τις δύο υλοποιήσεις με 4 executors (1 core, 2GB memory). Να συγκρίνετε και να σχολιάσετε τους χρόνους εκτέλεσης μεταξύ των δύο υλοποιήσεων. (%)
4. Να υλοποιηθεί το **Query 3** χρησιμοποιώντας τα DataFrame και RDD APIs. Να εκτελέσετε και τις δύο υλοποιήσεις με 3 executors (1 cores, 2GB memory). Να συγκριθούν και να σχολιαστούν οι χρόνοι εκτέλεσης για την κάθε υλοποίηση. (20%)

5. Να υλοποιηθεί το **Query 4** χρησιμοποιώντας το DataFrame ή SQL API. Για τα joins που εκτελούνται, να αναφέρετε ποιες στρατηγικές επιλέγει ο optimizer του Spark και να σχολιάσετε τις επιλογές του. Προκειμένου να μελετήσετε την κάθετη και οριζόντια κλιμακωσιμότητα, να εκτελέσετε την υλοποίησή σας, καλείστε να εκτελέσετε την υλοποίησή σας

A. σε 2 executors με τα ακόλουθα configurations:

- 1 core, 2 GB memory
- 2 cores, 4GB memory
- 4 cores, 8GB memory

B. χρησιμοποιώντας συνολικούς πόρους 8 cores και 16GB μνήμης με τα παρακάτω configurations:

- 2 executors $\times$ 4 cores, 8GB memory
- 4 executors $\times$ 2 cores, 4GB memory
- 8 executors $\times$ 1 core, 2GB memory

Σχολιάστε τα αποτελέσματα. (20%)

6. Στη περίπτωση των **Query 3** (DataFrame API) και **Query 4**, χρησιμοποιήστε τις μεθόδους [hint](#) και [explain](#) για να βρείτε ποιες στρατηγικές join χρησιμοποιεί ο catalyst optimizer. Πειραματιστείτε προτρέποντας το Spark να χρησιμοποιήσει διαφορετικές στρατηγικές (μεταξύ των BROADCAST, MERGE, SHUFFLE_HASH, SHUFFLE_REPLICATE_NL) και σχολιάστε την επίδραση στην επίδοση. Ποιά (ή ποιές) από τις διαθέσιμες στρατηγικές join του Spark είναι καταλληλότερη(ες) και γιατί;

Παραδοτέα - Όροι Υποβολής

- Η εργασία να εκπονηθεί αυστηρά ατομικά.
- Η προθεσμία παράδοσης θα καθοριστεί στο [helios](#) σε link που θα ανοίξει σύντομα.
- Η εργασία αποτελεί το 40% του συνολικού βαθμού του μαθήματος. Για να καταχωριθεί βαθμός, η κάθε ομάδα θα πρέπει να υποβάλει αναφορά **και** να περάσει επιτυχώς την υποχρεωτική προφορική εξέταση στο αντικείμενο της εργασίας. Η εξέταση θα γίνει μετά την παράδοση της εργασίας (θα αναρτηθεί σχετικό πρόγραμμα στο helios).
- Ως παραδοτέο θα υποβληθεί ένα .pdf αρχείο με όνομα τους AM των μελών της ομάδας χωρισμένα με κάτω παύλα (ή το AM του φοιτητή σε περίπτωση μονομελούς ομάδας), π.χ. 03100000.zip, ή 03100000_03100001.zip (ανάλογα με το πλήθος των ατόμων της ομάδας). Το αρχείο θα περιέχει μία αναφορά (αυστηρά με όσα ζητούνται στην εκφώνηση) η οποία θα περιέχει τις απαντήσεις στα ζητούμενα καθώς και απαραίτητα ένα link σε αποθετήριο (github, gitlab, bitbucket, etc.) με τους κώδικες που έχετε υλοποιήσει, όπως και πιθανά scripts/howtos για την εκτέλεση του κώδικά σας. Επίσης απαραίτητα, θα πρέπει να περιέχεται ένα αρχείο δήλωσης χρήσης LLM (λεπτομέρειες παρακάτω). Όλες οι υποβολές υπόκεινται αυστηρά στον κώδικα ακαδημαϊκής ηθικής του ΕΜΠ και της ΣΗΜΜΥ.

Ο κώδικάς σας δεν πρέπει να αλλάξει από την ημέρα παράδοσης της αναφοράς μέχρι και τη βαθμολόγηση του μαθήματος. Αν συμβεί αυτό η βαθμολογία σας θα είναι ΜΗΔΕΝ (0).

- Η χρήση εργαλείων LLM επιτρέπεται. Δεν επιτρέπεται η μη δηλωμένη ή παραπλανητική χρήση. Στο αρχείο LLM_USAGE.md δηλώνετε με ειλικρίνεια σε ένα πίνακα για κάθε ενότητα της εργασίας (κώδικα/κείμενο της αναφοράς) τα εξής: α) εργαλείο που χρησιμοποιήθηκε, β) έκταση χρήσης (πχ. “παρήγαγε τον αρχικό σκελετό”), γ) ποιο κομμάτι έγινε από εσάς χωρίς χρήση LLM.
- Ο/Η κάθε φοιτητής/φοιτήτρια μπορεί να υλοποιήσει τον κώδικά του σε Scala, Java ή Python. Είναι υποχρεωτικό να χρησιμοποιήσετε πόρους από την υποδομή του εργαστηρίου που σας έχει παραχωρηθεί για τις ανάγκες της εργασίας. Επίσης, είναι υποχρεωτικό να υπάρχει στην υποδομή του kubernetes ίχνος της τελευταίας εκτέλεσης κάθε υλοποίησής σας. Σε κάθε περίπτωση, η εξέταση θα απαιτήσει τη ζωντανή επίδειξη του κώδικά σας.
- Απορίες/επεξηγήσεις για την εργασία θα γίνονται μέσω forum στη σελίδα του μαθήματος στο

[helios](#). Μη στέλνετε απορίες στα email των διδασκόντων/βοηθών.